Progetto SFBIO

Xu Xin Yu

13 aprile 2026

Indice

1 Introduzione **4**

2 Background **5**

2.1 RCT - Studio controllato randomizzato 5

2.2 Definizioni utili 5

2.3 Assunti 6

2.3.1 *Stable Unit Treatment Value Assumption* (SUTVA) 6

2.3.2 Ignorabilità 6

2.3.3 Positività 6

2.4 *Treatment Effect* 7

2.5 Confondenti 7

3 Dataset eICU - CRD **8**

3.1 Descrizione Generale 8

3.2 Dimensioni e Popolazione 8

3.3 Struttura del Database 9

3.4 Segni Vitali 10

3.5 Sistema di Gravità APACHE 10

3.6 Deidentificazione e Accesso ai Dati 11

3.7 Prima fase esplorativa 11

4 Domanda Causale e Disegno dello Studio **15**

4.1 Domanda Causale 15

4.2 Target Trial Emulation 15

4.3 Criteri di Eligibilità 15

4.4 Assunzioni Causali 16

5 Metodi statistici **18**

5.1 Overview della pipeline 18

5.2 Propensity Score 18

5.3 IPW — Inverse Probability Weighting 18

5.4 AIPW - Augmented Inverse Probability Weighting 19

5.5 DragonNet 19

6 Diagnostica Causale **21**

6.1 Overlap e common support 21

6.2 Bilanciamento delle covariabili 21

6.3 Stabilità dei pesi IPW 22

6.4 Sensibilità 12h vs 24h 23

7 Risultati **24**

8 Discussione dei risultati **25**

8.1 Oltre l'apparenza: un risultato grezzo che inganna 25

8.2 Cosa cambia quando i conti tornano 25

8.3 Il duello tecnologico: DR Learner (XGBoost) vs DragonNet 25

8.4 Riflessioni pratiche 26

8.5 I limiti del nostro sguardo 26

8.6 Sintesi dei risultati 27

8.7 Conclusione 27

A Appendice: Iperparametri dell'Analisi **28**

A.1 Modello Logistico per il Propensity Score 28

A.2 Inverse Probability Weighting (IPW) 28

A.3 Bootstrap per Intervalli di Confidenza 28

A.4 DR Learner con XGBoost 29

A.5 Riepilogo degli Iperparametri 29

A.6 Note sulla Selezione degli Iperparametri 29

1 Introduzione

A chi studia Data Science e Machine Learning viene ripetuto con insistenza che *correlation does not imply causation*. Il concetto è ormai familiare, ma una domanda resta spesso implicita: che cosa intendiamo esattamente per causalità?

Si consideri uno studio secondo cui le ragazze che consumano regolarmente la colazione hanno, in media, un peso corporeo inferiore rispetto a quelle che la saltano. L'interpretazione più immediata è che fare colazione aiuti a dimagrire. Ma è altrettanto plausibile che chi fa colazione conduca, complessivamente, uno stile di vita più sano — più attività fisica, migliori abitudini alimentari, sonno regolare. Lo stile di vita agisce così come *confounding factor*, influenzando sia l'abitudine di fare colazione sia il peso corporeo. Correlazione, insomma, non significa ancora causalità.

Il gold standard per la stima degli effetti causali rimane il Randomized Controlled Trial (RCT). L'assegnazione casuale al trattamento garantisce che, in media, i gruppi trattato e controllo siano equivalenti rispetto a tutte le caratteristiche, osservate e non. Tuttavia, gli RCT sono spesso impraticabili per ragioni etiche, logistiche o economiche. Esiste poi una limitazione più profonda, comune anche agli RCT: la stessa unità non può essere osservata contemporaneamente come trattata e come non trattata. La ragazza dell'esempio non può fare colazione e saltarla allo stesso tempo.

A questo problema Rubin ha fornito una cornice concettuale chiara, il *potential outcome framework*. L'idea è che ogni unità possieda due esiti potenziali — quello che si osserverebbe sotto trattamento e quello che si osserverebbe sotto controllo — ma solo uno dei due sia effettivamente osservabile. L'altro rimane controfattuale. Questa asimmetria è nota come *fundamental problem of causal inference*.

Quando gli esperimenti randomizzati non sono realizzabili, si può tentare di stimare effetti causali a partire da dati osservazionali. Sono stati sviluppati a questo scopo diversi metodi statistici: il propensity score matching, l'Inverse Probability Weighting (IPW) e gli stimatori doppiamente robusti come l'AIPW. Questi approcci cercano di ricostruire, in modo inevitabilmente approssimato, le condizioni di un esperimento randomizzato, bilanciando i gruppi rispetto alle covariate misurate.

In questo progetto applichiamo tali metodi a un contesto clinico specifico. Utilizzando i dati osservazionali del database eICU-CRD (versione demo) Pollard et al. 2018, intendiamo stimare l'effetto causale della somministrazione precoce di antibiotici — entro 24 ore dal ricovero in terapia intensiva — sulla mortalità ospedaliera.

2 Background

L'inferenza **causale** è un metodo per determinare la **relazione di causa-effetto** tra **più** variabili, in altre parole, determinare che una variabile nè influenzi **un'altra**. L'inferenza **causale** va distinta dal concetto di **correlazione** tra dati: **quest'ultima** serve per rappresentare come due variabili **abbiano** un andamento crescente o decrescente. In particolare, l'inferenza **causale** è il processo mediante il quale si trae una conclusione su una connessione **causale** in base alle condizioni in cui si verifica un effetto.

2.1 RCT - Studio controllato randomizzato

Il modo **più efficace** per ottenere l'inferenza **causale** è lo **studio controllato randomizzato** (**RCT**, **randomized controlled trial**), in cui i partecipanti **vengono** assegnati in modo casuale a un gruppo che riceve il trattamento in studio **o** a un trattamento di controllo (un trattamento con placebo o nessun trattamento). Tale approccio non è **però** quello **più efficiente**: l'RCT è **costoso** e ***time consuming***, inoltre vanno fatte anche considerazioni etiche, che possono limitare l'attuazione dell'RCT; **nella realtà**, non è sempre applicabile per questi motivi **e** dunque la ricerca ha introdotto metodologie **più efficienti** per attuare l'inferenza **causale**.

[Yao et al. 2021] hanno definito un *survey* sui vari metodi di inferenza causale: metodi di ripoderazione; metodi di stratificazione; metodi di *matching*; metodi basati su alberi; representation based methods; metodi multi-task; e metodi di meta-apprendimento.

2.2 Definizioni utili

Si definiscono definizioni fondamentali nel contesto dell'inferenza causale.

- **Unità**: Oggetto fisico, come pazienti o persone individuali o un gruppo di oggetti come persone o una classe.
- **Trattamento**: Si riferisce all'azione che si deve applicare all'unità. Sia $W = \{0, 1, 2, ..., N_W\}$ l'insieme dei trattamenti dove $N_W + 1$ è il totale di tutti i trattamenti. Nell'inferenza causale **binaria** si defisce $W = 1$ come il gruppo trattato e $W = 0$ gruppo di controllo.
- **Risultato potenziale**: Il risultato che si *dovrebbe* ottenere per ogni coppia *unità* - trattamento. Si denota con $Y(W = w)$ dove $w \in W$
- **Risultato osservato**: Il risultato del trattamento che è stato effettivamente applicato. Si denota con $Y^F = Y(W = w)$

- **Risultato controfattuale**: Il risultato che si *sarebbe* ottenuto se fosse stato applicato un altro trattamento, oppure un insieme di trattamenti, in caso di inferenza non binaria. Dunque è l'insieme dei risultati potenziali tranne il risultato osservato. Nel trattamento multiplo si denota $Y^{CF}(W = w')$ dove w' sono i valori controfattuali. Nel trattamento binario si denota: $Y^{CF} = Y(W = 1 - w)$ dove w è il trattamento effettivamente ottenuto dall'unità
- **Variabili Pre-trattamento (o variabili di background)**: Sono variabili che non vengono influenzate dal trattamento. Si denota l'insieme delle variabili pre-trattamento come X
- **Variabili Post-trattamento**: Sono variabili che vengono influenzate dal trattamento.

2.3 Assunti

Per stimare l'effetto di un trattamento, i seguenti assunti sono spesso usate in letteratura. [Yao et al. 2021].

2.3.1 *Stable Unit Treatment Value Assumption* (SUTVA)

I risultati potenziali per qualsiasi unità non variano in base al trattamento assegnato ad altre unità e, per ciascuna unità, non esistono forme o versioni diverse di ciascun livello di trattamento che portino a risultati potenziali differenti.

I punti focali di questo assunto sono due:

- **Non intereferenza**: Il risultato controfattuale di un'unità non dipende dall'assegnazione di trattamento delle altre unità
- **Consisentaza**: Diversificare le versioni di un trattamento, due trattamenti sono ritenuti diversi anche cambi solo il dosaggio

2.3.2 Ignorabilità

Data la variabile di background X, l'assegnazione del trattamento W è indipendente dagli esiti potenziali.

In altre parole, che se prese due unitaà con stesse variabili di background, allora *dovrebbero* avere lo stesso risultato potenziale. In modo analogo, se due pazienti hanno le stesse variabili di background, *dovrebbero* avere lo stesso meccanismo di assegnamento del trattamento.

2.3.3 Positività

Per ogni valore di X, l'assegnazione del trattamento non è deterministica.

Se per alcuni valori di X l'assegnazione del trattamento è deterministica, allora per tali valori gli esiti di almeno un trattamento non potrebbero mai essere osservati. In questo caso, sarebbe impossibile e privo di significato stimare l'effetto del trattamento. Volendo fare un esempio, si supponga di avere due trattamenti: Farmaco A e Farmaco B. Ipotizziamo che ai pazienti con età superiore ai 60 anni venga sempre somministrato il Farmaco A; allora risulterebbe impossibile e privo di significato studiare l'esito del Farmaco B su tali pazienti. In altre parole, l'assunto di positività implica la **variabilità**, la quale è fondamentale per la stima dell'effetto del trattamento.

La combinazione degli assunti della ignorabilità e della positività viene anche chiamata come *Strong Ignorability* la quale ci permette di analizzare i risultati potenziale di diversi tipi di sotto gruppi.

2.4 *Treatment Effect*

L'effetto del trattamento può essere misurato per popolazione, gruppo trattato, in sotto gruppi oppure per unità singole. È una metrica fondamentale per capire l'effetto del trattamento a più livelli.

- **Average Treated Effect**: $ATE = \mathbb{E}[Y(W=1) - Y(W=0)]$
- **Average Treatment effect on the Treated Group**: $ATT = \mathbb{E}[Y(W=1)|W=1] - \mathbb{E}[Y(W=0)|W=1]$
- **Conditional Average Treatment Effect**: $CATE = \mathbb{E}[Y(W=1)|X=x] - \mathbb{E}[Y(W=0)|X=x]$
- **Individual Treatment Effect**: $ITE_i = Y_i(W=1) - Y_i(W=0)$

2.5 Confondenti

Le variabili confendenti sono variabili pre-addrestramento speciali, che influenza la scelta del trattamento e il risultato potenziale dello stesso. Per esempio in campo medico, età è una variabile confondente, influenza i risultati potenziali poichè i pazienti più giovani potrebbero recuperare in modo più veloce e naturale dalla malattia che pazienti più anziani. Le variabili confondenti creano un problema sulle stime dei controfattuali e sullo studio dell'effetto del trattamento. Le variabili confondenti influenzano anche la scelta del trattamento, causando ***selection bias***.

3 Dataset eICU - CRD

3.1 Descrizione Generale

L'**eICU Collaborative Research Database** (eICU-CRD) è un database multicentrico ad alta granularità per la ricerca in terapia intensiva, sviluppato congiuntamente dal Laboratory for Computational Physiology (LCP) del MIT e dall'eICU Research Institute (eRI) di Philips Healthcare [Pollard et al. 2018]. Il database è derivato dal programma eICU, un sistema di telehealth per il monitoraggio remoto dei pazienti critici ricoverati nelle Unità di Terapia Intensiva (UTI) degli Stati Uniti. I dati vengono documentati nel sistema di gestione clinica *eCareManager* e successivamente archiviati e trasformati in un database di ricerca. Il database è distribuito in formato CSV, caricabile in qualsiasi sistema di gestione di basi di dati relazionali, e reso pubblicamente disponibile tramite il repository PhysioNet, previa registrazione, completamento di un corso sulla ricerca con soggetti umani e firma di un accordo sull'uso dei dati.

3.2 Dimensioni e Popolazione

Il database comprende **200.859 ricoveri in UTI** relativi a **139.367 pazienti unici**, ammessi tra il 2014 e il 2015 in **335 unità** distribuite su **208 ospedali** negli Stati Uniti. La selezione dei pazienti è stata effettuata mediante campionamento casuale stratificato per ospedale: per ciascun paziente è stato selezionato un ricovero indice, e tutti i ricoveri successivi dello stesso paziente sono stati inclusi indipendentemente dall'ospedale di ammissione. L'obiettivo della stratificazione era preservare la distribuzione dei primi ricoveri in UTI tra i diversi ospedali presenti nel repository originale di eRI. La Tabella 1 riassume le principali caratteristiche demografiche della popolazione inclusa nel database.

Tabella 1. Caratteristiche demografiche dei 200.859 ricoveri in UTI presenti nel database. Più ricoveri possono corrispondere allo stesso paziente.

Variabile	**Valore**
Età, anni (mediana [IQR])	65,00 [53,00 – 76,00]
Durata ricovero in UTI, giorni	1,57 [0,82 – 2,97]
Durata ricovero ospedaliero, giorni	5,49 [2,90 – 10,04]
Altezza all'ammissione, cm (media ± DS)	169,25 ± 13,69
Peso all'ammissione, kg (media ± DS)	83,93 ± 27,09
Genere	
Maschio	108.379 (53,96%)
Femmina	92.303 (45,95%)
Altro/Sconosciuto	177 (0,09%)
Etnia	
Caucasico	155.285 (77,31%)
Afroamericano	21.308 (10,61%)
Ispanico	7.464 (3,72%)
Asiatico	3.270 (1,63%)
Nativo Americano	1.700 (0,85%)
Altro/Sconosciuto	11.832 (5,89%)
Stato alla dimissione dall'UTI	
Vivo	189.918 (94,55%)
Deceduto	10.907 (5,43%)
Sconosciuto	34 (0,02%)
Stato alla dimissione ospedaliera	
Vivo	181.104 (90,16%)
Deceduto	18.004 (8,96%)
Sconosciuto	1.751 (0,87%)

3.3 Struttura del Database

Il database è organizzato in uno schema altamente denormalizzato composto da un insieme di tabelle (si veda la Tabella 4 del paper originale per l'elenco completo), ciascuna delle quali può essere collegata alla tabella principale `patient` tramite l'identificatore univoco `patientUnitStayId`. L'unica eccezione è la tabella `hospital`, che si collega a `patient` tramite `hospitalId`. Le tabelle sono raggruppabili nelle seguenti macro-categorie:

- **Dati amministrativi:** informazioni demografiche del paziente, tipo di unità,

provenienza, esito della dimissione (`patient`, `hospital`).

- **Dati APACHE:** parametri fisiologici e predizioni di mortalità basate sul sistema APACHE IV e IVa (`apacheApsVar`, `apachePredVar`, `apachePatientResult`).
- **Piano di cura:** documentazione intraprofessionale su tipo di provider, codice di stato, prognosi e cure di fine vita (`carePlanGeneral`, `carePlanGoal`, `carePlanEOL`, ecc.).
- **Documentazione clinica:** problemi attivi, trattamenti, farmaci, esami di laboratorio, microbiologia, note cliniche, valutazioni infermieristiche e parametri respiratori (18 tabelle dedicate).
- **Dati da monitor:** segni vitali ad alta frequenza derivati direttamente dai monitor al letto, senza validazione umana (`vitalPeriodic`, `vitalAperiodic`).

3.4 Segni Vitali

La tabella `vitalPeriodic` contiene le misurazioni continue dei segni vitali, originariamente campionate a intervalli di 1 minuto e archiviate come mediane su finestre di 5 minuti. Le variabili disponibili includono frequenza cardiaca, saturazione periferica dell'ossigeno, frequenza respiratoria, temperatura, pressione arteriosa invasiva, livelli ST e pressione intracranica (ICP). La frequenza cardiaca è il parametro più rappresentato (disponibile per il 95,73% dei pazienti), mentre l'ICP è il meno frequente (0,81% dei pazienti). La tabella `vitalAperiodic` raccoglie invece i segni vitali misurati in modo aperiodico, quali la pressione arteriosa non invasiva (disponibile per il 94% dei pazienti), la gittata cardiaca e le resistenze vascolari sistemiche e polmonari.

3.5 Sistema di Gravità APACHE

Il sistema **APACHE IV** (*Acute Physiology, Age, and Chronic Health Evaluation*) è uno strumento di risk-adjustment basato sui dati delle prime 24 ore di ricovero in UTI, utilizzato per stimare la probabilità di mortalità ospedaliera. Il database include tutti i parametri dell'equazione APACHE IV, nonché le predizioni del modello aggiornato APACHE IVa. Tali predizioni non sono disponibili per tutti i pazienti: ne sono esclusi coloro con degenza inferiore a quattro ore, i pazienti ustionati, alcuni trapiantati e i ricoveri ripetuti in-hospital ($N = 64.623$ pazienti esclusi). Le diagnosi di ammissione più frequenti nel sottoinsieme con predizione APACHE IV disponibile ($N = 136.236$) comprendono sepsi polmonare (5,01%), infarto miocardico acuto (4,34%) e ictus cerebrovascolare (3,88%).

3.6 Deidentificazione e Accesso ai Dati

Il database è stato deidentificato in conformità alle disposizioni *safe harbor* dell'HIPAA (*Health Insurance Portability and Accountability Act*), con rimozione di tutti i dati identificativi personali, inclusi nomi, indirizzi, date e età superiori agli 89 anni. Il rischio di re-identificazione è stato certificato da Privacert (Cambridge, MA) (Certificazione HIPAA n. 1031219-2). I campi di testo libero sono stati inoltre scansionati con un approccio automatico basato su regole per rilevare eventuali informazioni residue, seguiti da una revisione manuale da parte di almeno tre revisori per tabella. L'accesso ai dati avviene attraverso il repository PhysioNet e richiede: (i) il completamento di un corso sulla ricerca con soggetti umani (es. CITI Program), e (ii) la firma di un accordo sull'uso dei dati che vieta la condivisione e il tentativo di re-identificazione di pazienti o istituzioni, e impone la pubblicazione del codice associato a eventuali lavori scientifici.

3.7 Prima fase esplorativa

In questa sezione vengono riportati i risultati ottenuti dalla prima fase esplorativa del dataset. Un'analisi descrittiva della popolazione è già presente in Pollard et al. 2018; il presente lavoro propone un'analisi esplorativa sulla versione demo del dataset, accessibile pubblicamente senza restrizioni.

Età ed etnia La distribuzione di età ed etnia rispecchia quanto riportato in Pollard et al. 2018: il sesso risulta relativamente bilanciato e il gruppo etnico di maggioranza, con ampio margine, è quello caucasico (figura 1).

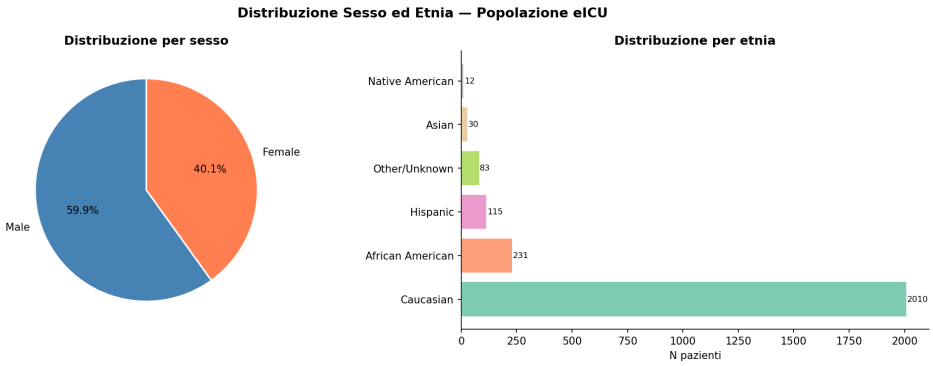

Figura 1. Distribuzione per sesso ed etnia nella popolazione in studio.

Decessi I decessi rappresentano un dato di particolare rilevanza per l'obiettivo di questo studio di inferenza causale, in quanto costituiscono un candidato naturale come outcome nel framework del *potential outcome*. La figura 2 mostra la distribuzione percentuale dei decessi a livello globale, comprensiva sia delle morti avvenute

all'interno dell'unità di terapia intensiva che di quelle registrate successivamente durante il ricovero ospedaliero.

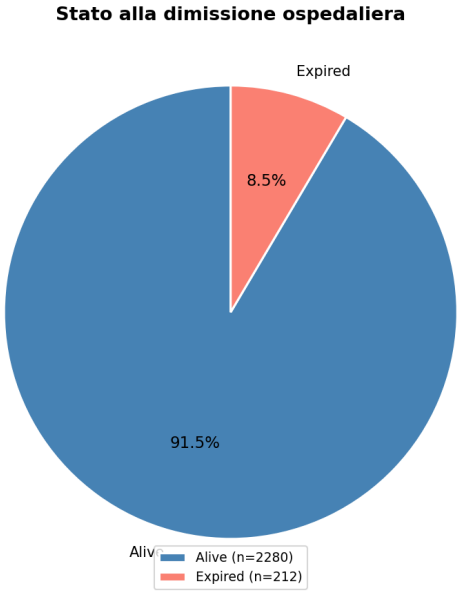

Figura 2. Distribuzione percentuale dei decessi globali nella popolazione in studio.

Analizzando il tasso di mortalità per fascia d'età, come illustrato in figura 3, si osserva un andamento complessivamente crescente all'aumentare dell'età. Tale pattern risulta più evidente escludendo la fascia <18 anni, la quale — pur presentando un tasso di mortalità elevato (25%) — rappresenta una porzione marginale della popolazione in studio (0,2% del totale) e non è pertanto statisticamente rappresentativa.

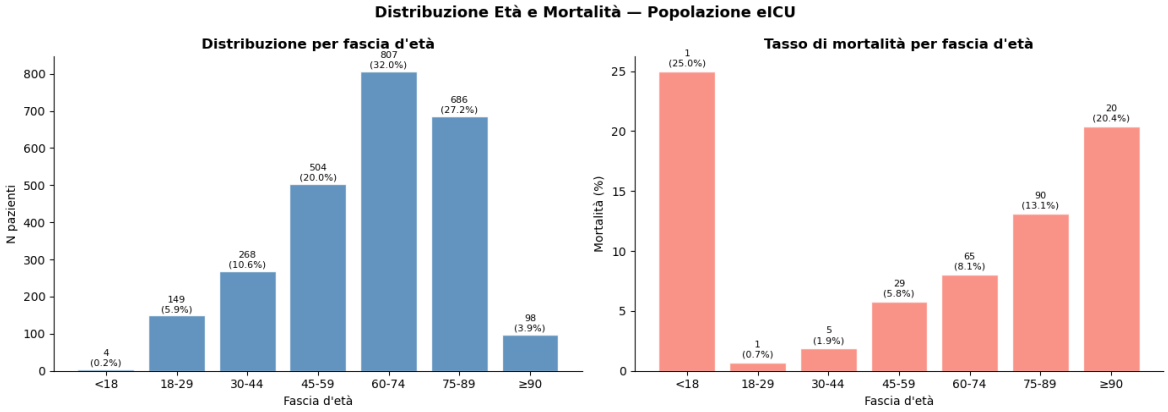

Figura 3. Tasso di mortalità ospedaliera per fascia d'età nella popolazione in studio.

Trattamenti e diagnosi La conoscenza approfondita dei trattamenti presenti nel dataset è fondamentale, essendo questi il punto centrale dello studio. Come illustrato

in figura 4, i trattamenti più frequentemente applicati ai pazienti sono: 1) *mechanical ventilation*, 2) *chest x-ray* e 3) *normal saline administration*.

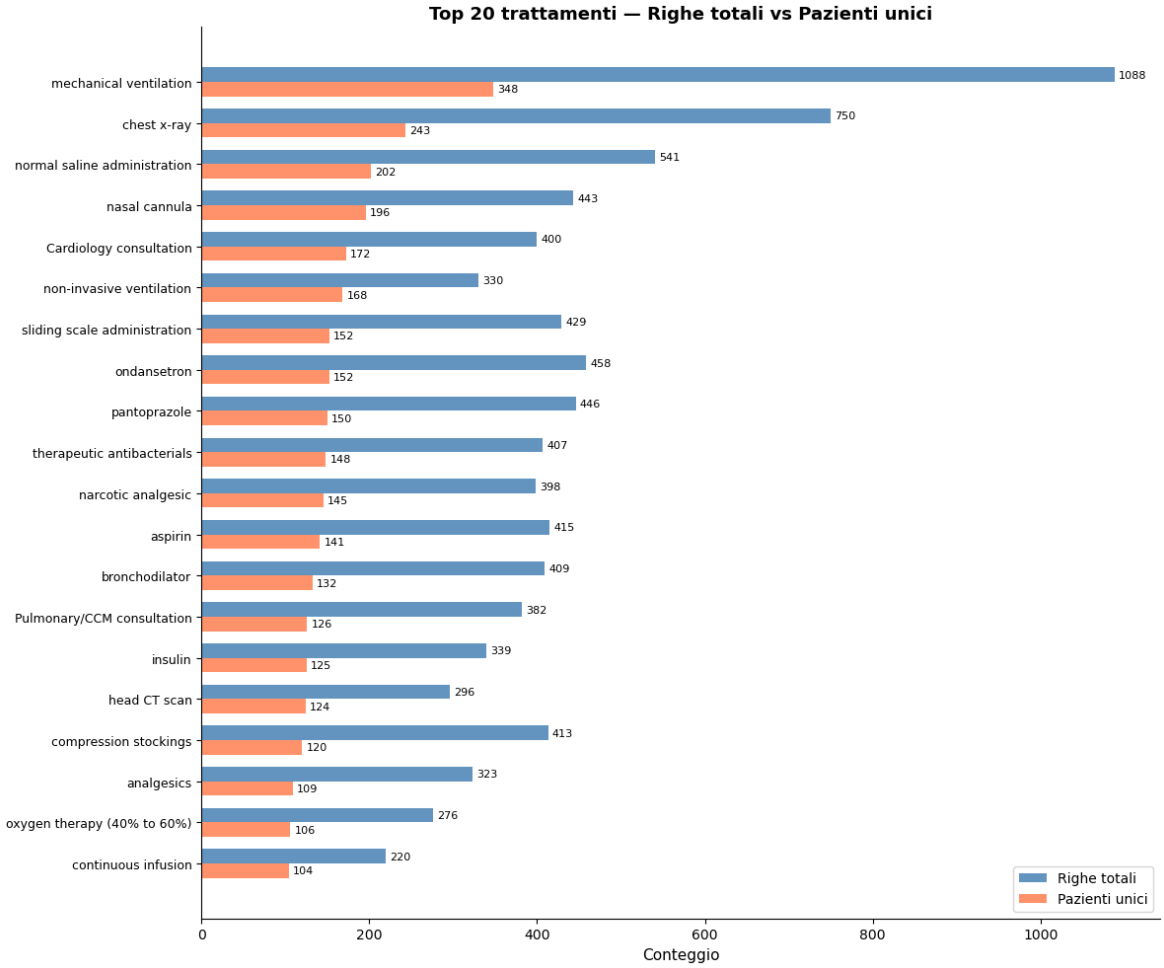

Figura 4. Distribuzione dei trattamenti per frequenza globale e per pazienti unici.

Altrettanto rilevante è la distribuzione delle diagnosi (figura 5), le quali rivestono il ruolo di *confondenti* nel disegno causale adottato. La diagnosi è infatti determinante nell'assegnazione dei trattamenti: essa definisce il profilo clinico del paziente e orienta le decisioni terapeutiche, introducendo un meccanismo di *confounding by indication* che deve essere opportunamente controllato nell'analisi.

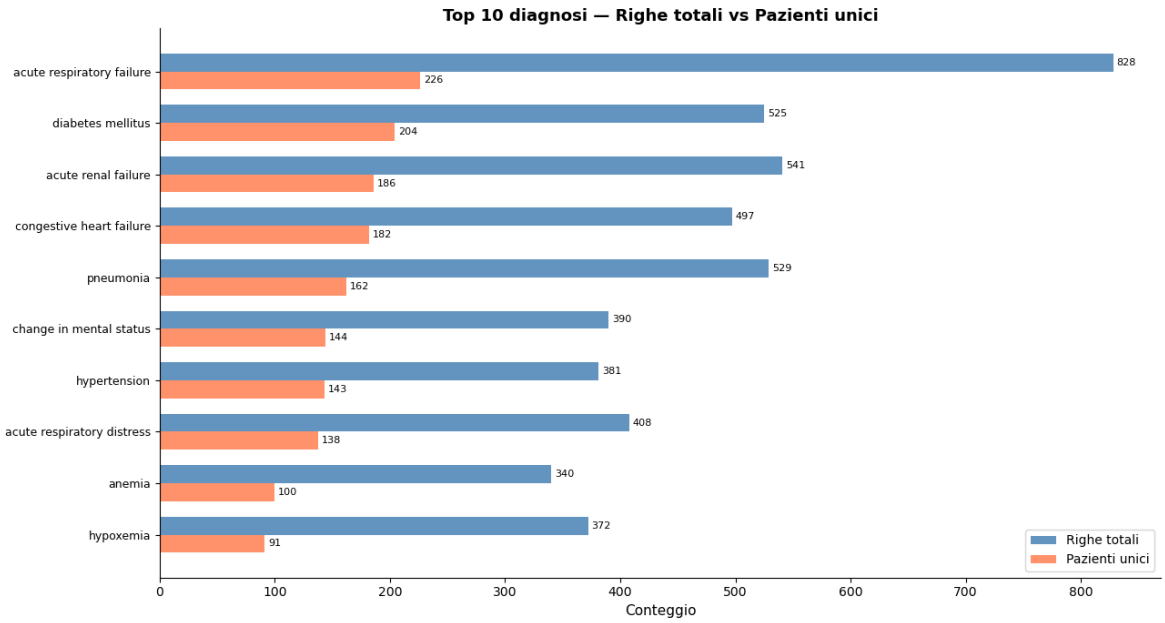

Figura 5. Distribuzione delle diagnosi per frequenza globale e per pazienti unici.

A conferma di ciò, la figura 6 mostra la distribuzione dei trattamenti per le cinque diagnosi più frequenti, evidenziando come il pattern terapeutico vari considerevolmente in funzione della diagnosi di ammissione.

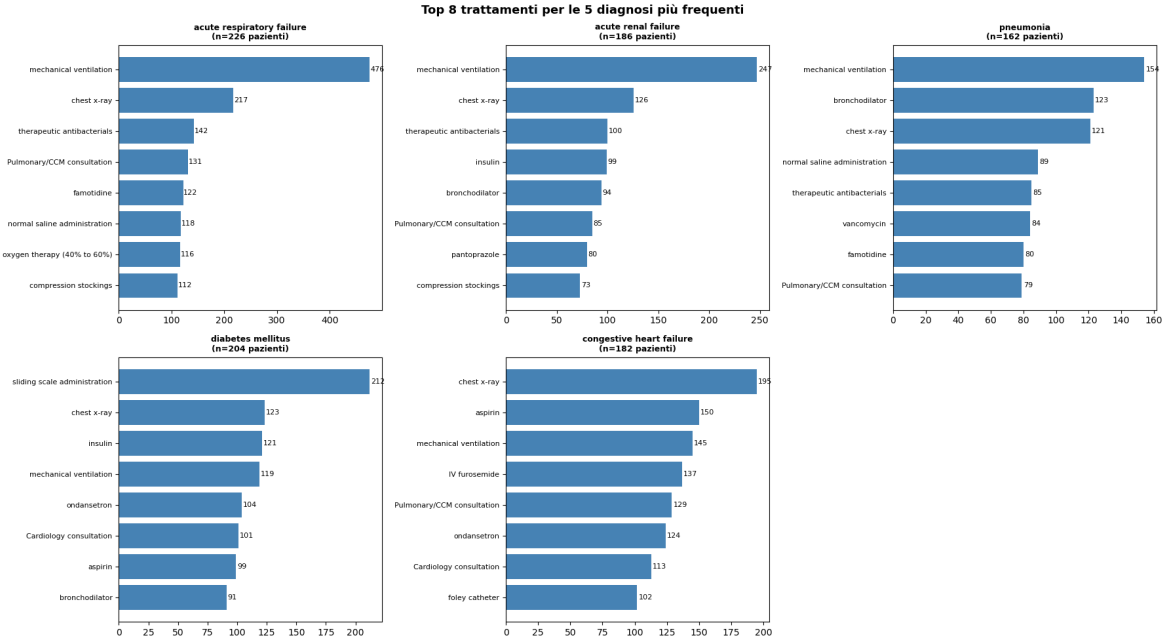

Figura 6. Distribuzione dei trattamenti per le cinque diagnosi più frequenti.

4 Domanda Causale e Disegno dello Studio

4.1 Domanda Causale

La presente analisi si propone di stimare l'effetto causale della somministrazione precoce di antibiotici terapeutici sulla mortalità ospedaliera in pazienti adulti ricoverati in terapia intensiva (ICU). Formalmente, la domanda causale è la seguente:

> *Nei pazienti adulti ricoverati per la prima volta in ICU, la somministrazione di antibiotici terapeutici entro le prime 24 ore dall'ammissione riduce la mortalità ospedaliera rispetto alla mancata somministrazione o alla somministrazione tardiva?*

Il trattamento di interesse (A) è definita come la ricezione di almeno un antibiotico terapeutico entro 1440 minuti dall'ammissione in ICU ($A = 1$) versus assenza di antibiotici terapeutici entro tale finestra ($A = 0$). L'outcome (Y) è la mortalità ospedaliera (`hospitaldischargestatus` = "Expired"). L'estimand pre-specificato è l'*Average Treatment Effect* (ATE), ovvero l'effetto medio nella popolazione della coorte.

4.2 Target Trial Emulation

Per strutturare l'analisi in modo rigoroso e limitare i bias metodologici comuni negli studi osservazionali, abbiamo adottato il framework del *Target Trial Emulation* (TTE) [Hernán et al. 2022]. Il TTE prevede due step sequenziali: la specificazione esplicita del trial randomizzato ipotetico che risponderebbe alla domanda causale (*target trial*), e la successiva emulazione di tale trial utilizzando dati osservazionali [Fu 2023]. Questo approccio consente di identificare e prevenire bias comuni quali l'immortal time bias e il leakage di variabili post-trattamento, che frequentemente affliggono gli studi osservazionali non strutturati [Hernán et al. 2022].

Il protocollo del target trial emulato è riportato nella Tabella 2.

4.3 Criteri di Eligibilità

La coorte è stata costruita applicando sequenzialmente i seguenti criteri di inclusione ed esclusione:

- **Inclusione**: pazienti adulti ($\geq$18 anni); primo ricovero in ICU (`unitvisitnumber` = 1); durata dello stay $\geq$ 4 ore; stato di dimissione ospedaliero definibile (`hospitaldischargestatus` $\in$ {"Alive", "Expired"}).
- **Esclusione**: pazienti con ordini di *comfort care* o *end-of-life* documentati all'ammissione (tabella `carePlanEOL`), in quanto il loro outcome è determinato

indipendentemente dal trattamento; pazienti con evidenza di antibiotici terapeutici somministrati prima dell'ammissione in ICU (`treatmentoffset` < 0), per i quali il time zero non è definibile in modo pulito.

La coorte finale comprende **1.970 pazienti**, di cui 389 (19,7%) con $A = 1$ e 1.581 (80,3%) con $A = 0$. La mortalità ospedaliera grezza è risultata del 10,8% nel gruppo $A = 1$ e del 7,3% nel gruppo $A = 0$, con una differenza grezza di $+3,5$ punti percentuali attribuibile al *confounding by indication*: i pazienti che ricevono antibiotici precocemente sono sistematicamente più gravi al basale rispetto a quelli che non li ricevono (Apache score medio: 55,2 vs 49,7).

4.4 Assunzioni Causali

L'interpretazione causale dell'ATE stimato richiede la validità delle seguenti assunzioni [Austin e Stuart 2015; Yao et al. 2021]:

1. **Exchangeability condizionale** (*no unmeasured confounding*): condizionatamente alle 30 covariate basali incluse, l'assegnazione al trattamento è indipendente dai potenziali outcome. Questa assunzione non è verificabile empiricamente; la sua plausibilità dipende dalla completezza delle covariate misurate. Le caratteristiche ospedaliere (pratiche cliniche, protocolli locali) rappresentano una fonte potenziale di confounding residuo non misurato.

2. **Positivity**: per ogni combinazione di valori delle covariate osservata nel campione, esistono sia pazienti trattati che non trattati. La distribuzione del propensity score mostra sovrapposizione adeguata tra i gruppi (AUC = 0,78; 98% dei pazienti nella regione di overlap comune), con una minoranza di pesi estremi gestita mediante clipping al 99° percentile.

3. **Consistency**: il trattamento è sufficientemente ben definita da garantire che variazioni nella sua forma non producano outcome diversi. Una potenziale violazione riguarda l'eterogeneità degli antibiotici terapeutici inclusi (vancomicina, beta-lattamici, fluorochinoloni, ecc.), che potrebbero avere effetti differenziali a seconda del patogeno e della diagnosi.

4. **Assenza di misspecification del modello**: il propensity score e il modello di outcome sono stati stimati mediante regressione logistica con regolarizzazione ($C = 0.1$). Il bilanciamento è stato verificato mediante la *Standardized Mean Difference* (SMD) per tutte le covariate incluse, con target $|\text{SMD}| < 0.1$ dopo la pesatura.

Tabella 2. Protocollo del Target Trial Emulato

Elemento	**Specificazione**
Popolazione	Pazienti adulti ($\geq$18 anni) al primo ricovero in ICU, con durata dello stay $\geq$4 ore, outcome ospedaliero definibile, senza ordini di comfort care all'ammissione, e senza evidenza di somministrazione di antibiotici terapeutici prima del ricovero in ICU (offset < 0 minuti).
Time zero (t_0)	Momento dell'ammissione in ICU (`hospitaladmitoffset`).
Trattamento A	Ricezione di almeno un antibiotico terapeutico (escludendo gli antibiotici profilattici) entro la finestra $[t_0,\ t_0{+}1440$ min$]$. $A = 1$ se trattato, $A = 0$ altrimenti.
Finestra di assegnazione	$[t_0,\ t_0 + 24$ h$]$. Tutte le covariate (X) sono state estratte precedentemente o contestualmente a tale finestra, in accordo con la regola d'oro del TTE per evitare l'aggiustamento per mediatori Hernán et al. 2022.
Outcome Y	Mortalità ospedaliera, definita come `hospitaldischargestatus` = "Expired". Misurata dalla dimissione ospedaliera, coerentemente con l'orizzonte temporale del target trial.
Estimand	Average Treatment Effect (ATE): effetto medio del trattamento nella popolazione della coorte, ovvero ATE $= \mathbb{E}[Y(1) - Y(0)]$, dove $Y(a)$ indica il potenziale outcome sotto assegnazione $A = a$.
Follow-up	Dalla data di ammissione in ICU (t_0) fino alla dimissione ospedaliera o al decesso. Non sono presenti eventi di censura nel dataset demo.
Piano di analisi	Inverse Probability of Treatment Weighting (IPTW) con pesi stabilizzati come metodo baseline; Augmented IPTW (AIPW, doubly robust) come metodo principale Austin e Stuart 2015. Intervalli di confidenza al 95% stimati mediante bootstrap ($B = 500$ iterazioni).

5 Metodi statistici

5.1 Overview della pipeline

La strategia analitica prevende la misurazione dello stimatore ATE:

- **Naive**: differenza grezza delle medie dell'outcome fra i gruppi, senza aggiustamento.
- **IPW**: *Inverse Probability Weighting* basato sul propensity score.
- **AIPW** Augumented IPW*doubly robust*.
- **DragonNet** rete neurale multi-task con *targeted regularization*

5.2 Propensity Score

Il propensity score $e(X) = \Pr(A = 1 \mid X)$ è stimato tramite regressione logistica con regolarizzazione ℓ_2 ($C = 0.1$, massimo 1000 iterazioni):

$$\hat{e}(X) = \sigma\big(\hat{\beta}^\top X\big), \quad \hat{e}(X) \text{ clippato in } [0.01, 0.99].$$

L'AUC sul campione di addestramento è risultata pari a **0.776**, indicando un buon potere discriminante.

5.3 IPW — Inverse Probability Weighting

L'Inverse Probability Weighting (IPW) è una tecnica ampiamente utilizzata in epidemiologia, biostatistica e scienze sociali per stimare effetti causali a partire da dati osservazionali.

L'IPW mira a ricostruire, in un contesto osservazionale, il bilanciamento che ci si aspetterebbe da un randomized controlled trial (RCT). In un RCT, l'assegnazione al trattamento è indipendente dalle covariate; nei dati osservazionali, invece, il trattamento è spesso associato a caratteristiche del paziente (confounding by indication).

Attraverso la pesatura:

- Ai pazienti trattati che hanno una bassa probabilità di ricevere il trattamento (dati il loro profilo di covariate) viene assegnato un peso elevato, perché sono "rari" tra i trattati e contribuiscono a bilanciare il gruppo.
- Ai pazienti non trattati che hanno un'alta probabilità di ricevere il trattamento viene assegnato un peso elevato, perché sono "rari" tra i non trattati.

Il risultato è un campione ponderato in cui la distribuzione delle covariate è bilanciata tra i due gruppi di esposizione. I pesi IPTW stabilizzati sono definiti come:

$$w_i = \frac{A_i \bar{p}}{\hat{e}(X_i)} + \frac{(1 - A_i)(1 - \bar{p})}{1 - \hat{e}(X_i)}, \quad \bar{p} = \frac{1}{n} \sum_i A_i.$$

Lo stimatore dell'ATE in IPW è definito nella formula seguente:

$$\widehat{\mathrm{ATE}}_{\mathrm{IPW}} = \frac{\sum_i w_i A_i Y_i}{\sum_i w_i A_i} - \frac{\sum_i w_i (1 - A_i) Y_i}{\sum_i w_i (1 - A_i)}.$$

5.4 AIPW - Augmented Inverse Probability Weighting

L'**Augumented Inverse Probability Weighting** è un metodo di stima dell'effetto causale che comabina l'IPW con un modello di outcome (regressione), ottendendo uno stimatore **doppiamente robusto**. Definiamo lo score per il gruppo trattamento (A=1) e per il gruppo di controllo (A=0):

$$\hat{\psi}_1^{(i)} = \overbrace{\hat{\mu}_1(X_i)}^{\text{modello outcome}} + \underbrace{\frac{A_i\big(Y_i - \hat{\mu}_1(X_i)\big)}{\hat{e}(X_i)}}_{\text{correzione IPW (trattati)}}$$

$$\hat{\psi}_0^{(i)} = \overbrace{\hat{\mu}_0(X_i)}^{\text{modello outcome}} + \underbrace{\frac{(1 - A_i)\big(Y_i - \hat{\mu}_0(X_i)\big)}{1 - \hat{e}(X_i)}}_{\text{correzione IPW (controlli)}}$$

Lo stimatore dell'ATE in AIPW è definito nella formula seguente:

$$\widehat{\mathrm{ATE}}_{\mathrm{AIPW}} = \frac{1}{n} \sum_{i=1}^{n} \left(\hat{\psi}_1^{(i)} - \hat{\psi}_0^{(i)} \right)$$

5.5 DragonNet

Per stimare l'ATE con un approccio più flessibile rispetto ai metodi parametrici, abbiamo utilizzato **DragonNet** [Shi et al. 2019], un'architettura neurale introdotta specificamente per l'inferenza causale da dati osservazionali.

L'idea di fondo è semplice: invece di addestrare reti separate per il propensity score e per i modelli di outcome, DragonNet le unifica in un'unica architettura a tre teste. Un blocco di strati condivisi apprende una rappresentazione comune $Z(X) \in \mathbb{R}^p$ dalle covariabili; da questa rappresentazione partono poi tre rami distinti — uno per $\hat{\mu}_1(X)$, uno per $\hat{\mu}_0(X)$, e uno per il propensity score $\hat{g}(X) = \Pr(A = 1 \mid X)$. La giustificazione teorica è che il propensity score è *sufficiente* per l'aggiustamen-

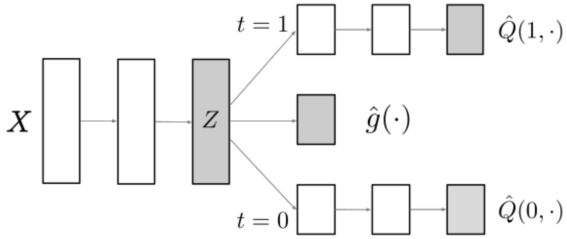

Figura 7. Architettura DragonNet [Shi et al. 2019
]

to causale: costringere la rete a predirlo esplicitamente la spinge a imparare una rappresentazione che cattura le informazioni rilevanti per la causalità, ignorando il resto.

A questo si aggiunge la *targeted regularization*, un termine extra nella loss che non si limita a minimizzare l'errore di predizione, ma orienta attivamente la rete verso stime con buone proprietà statistiche asintotiche — analogamente a quanto fa il TMLE nella letteratura semiparametrica. In pratica, questo significa che la rete non ottimizza solo per predire bene Y, ma anche per produrre una stima dell'ATE più stabile e meno sensibile a errori di specificazione.

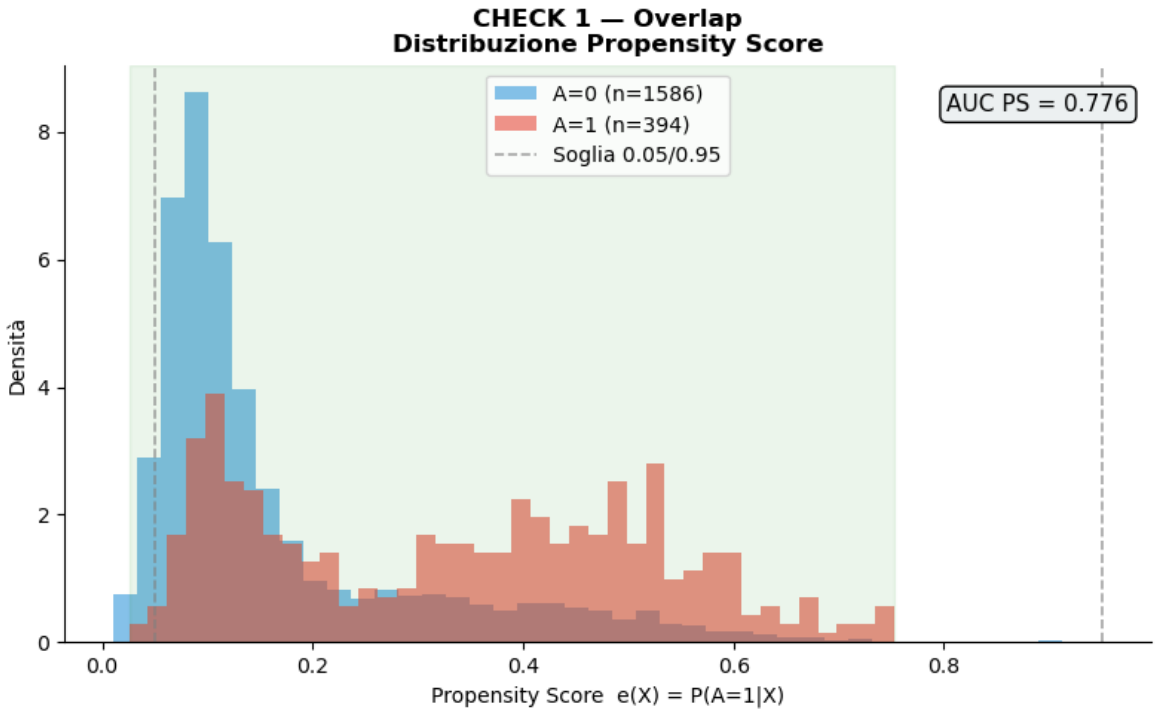

Figura 8. Grafico del overlap delle covariate dei due gruppi

6 Diagnostica Causale

6.1 Overlap e common support

La distribuzione del propensity score nei due gruppi è stata analizzata per verificare l'assunzione di positivity. Il modello logistico raggiunge un'AUC di 0.776, indicando un discreto potere discriminante coerente con la presenza di confounding per indicazione. La distribuzione del PS nei trattati (mediana ≈ 0.35) è spostata verso destra rispetto ai controlli (mediana ≈ 0.12), ma le due distribuzioni si sovrappongono ampiamente nella regione centrale. Solo 83 pazienti (4.2%) presentano un PS estremo (< 0.05 o > 0.95), una quota trascurabile che non compromette l'inferenza causale. Non è stato applicato trimming.

6.2 Bilanciamento delle covariabili

Il bilanciamento è valutato tramite lo Standardized Mean Difference (SMD) prima e dopo la pesatura IPW, utilizzando la soglia convenzionale $|\text{SMD}| < 0.10$. Prima della pesatura, diverse covariabili mostrano uno sbilanciamento rilevante: `infective_dx` ($|\text{SMD}| \approx 0.80$), `aps_heartrate` e `predictedhospitalmortality` presentano i valori più elevati, confermando il confounding per indicazione atteso. Dopo la pesatura IPW, 29 covariabili su 31 (94%) rientrano nella soglia $|\text{SMD}| < 0.10$. Le duecovariabili residualmente sbilanciate (`aps_creatinine`, $|\text{SMD}| = 0.038$;

`aps_heartrate`, $|\text{SMD}| = 0.040$) rimangono comunque al di sotto di qualsiasi soglia di rilevanza pratica, e il loro impatto sulla stima dell'ATE è atteso essere trascurabile.

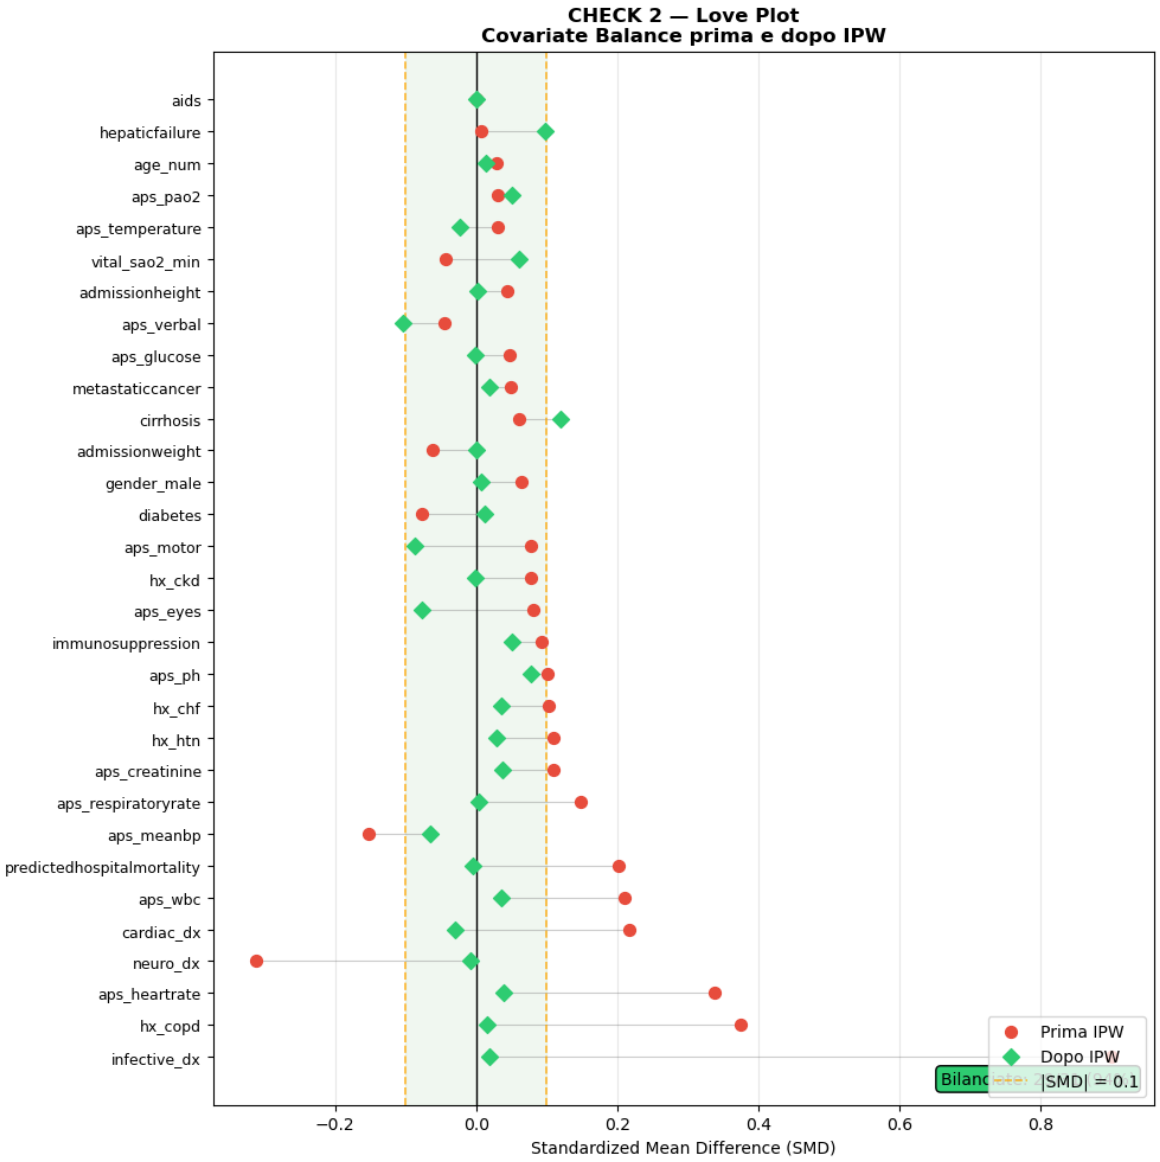

Figura 9. Loveplot delle covariate

6.3 Stabilità dei pesi IPW

I pesi IPTW stabilizzati presentano una distribuzione ben comportata. La mediana è pari a 0.90, coerente con quanto atteso per pesi correttamente stabilizzati. Il 95 percentile è 1.78 e il 99 percentile è 2.60, con un valore massimo di circa 9. Solo 20 pazienti (1.0%) superano la soglia P99, confermando l'assenza di pesi estremi destabilizzanti. Come atteso in presenza di trattamento non bilanciato ($A = 1$: 19.9%), i pesi dei trattati mostrano una dispersione maggiore rispetto a quelli dei controlli: i pazienti trattati con basso PS, quelli che ci si aspettava non ricevessero

antibiotici ma che invece li hanno ricevuti, ottengono pesi più elevati, rendendoli informativamente più rilevanti per la stima causale. Non è stato necessario alcun clipping aggiuntivo.

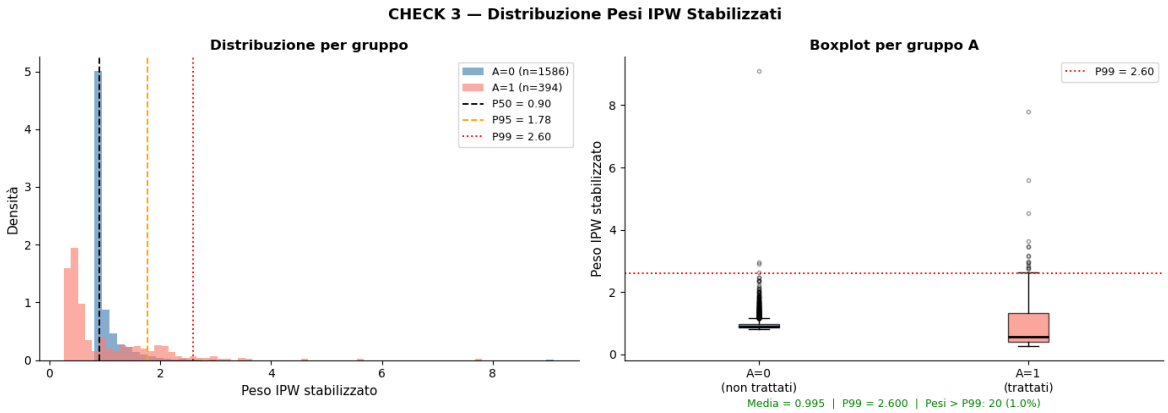

Figura 10. Distribuzione dei pesi IPW stabilizzati

6.4 Sensibilità 12h vs 24h

Per far un controllo sulla sensibilità riguardante il *time-offset* del trattamento è stata fatta un'analisi sulla coorte seguendo i criteri di inclusione ed esclusione discussi nel Capitolo 4, andando a modificare la finestra di trattamento da 24h -> 12h. Andando ad analizzare le due coorti non sono presenti differenze di popolazione nè di covariate da giustificare un'analisi ulteriore.

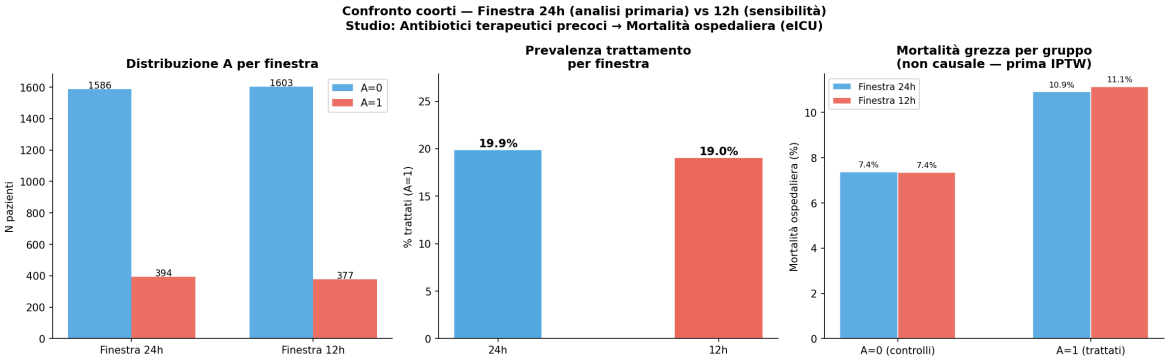

Figura 11. Differenze fra 12h, 24h.

7 Risultati

In questo capitolo vengono mostrati i risultati ottenuti, cioè come si comporta l'estimatore ATE in **IPW**, **AIPW**, **DragonNet** e **DR Learner** con **XGBoost**.

Tabella 3. Risultati dell'analisi causale - Confronto dei metodi

Metodo	**ATE**	**IC 95%**	**Significatività**
Naive	$+3.54\%$	–	Confounding evidente
IPW	$+0.07\%$	$[-2.85\%, +4.45\%]$	NON sign. ($p > 0.05$)
AIPW	$+0.14\%$	$[-3.46\%, +2.96\%]$	NON sign. ($p > 0.05$)
DragonNet	-1.86%	$[-59.17\%, +71.60\%]$	Impreciso (IC ampio)
DR Learner (XGBoost)	$+1.23\%$	$[-0.86\%, +4.47\%]$	NON sign. ($p > 0.05$)

Note metodologiche:
- AUC del propensity score (modello logistico regolarizzato): 0.776
- Pesi IPTW stabilizzati, clipping al 99° percentile
- Bootstrap con $B = 500$ iterazioni per IC 95%
- DR Learner implementato con XGBoost (100 estimator, max depth = 3)

8 Discussione dei risultati

8.1 Oltre l'apparenza: un risultato grezzo che inganna

Se ci fermassimo alla superficie dei numeri, la conclusione sarebbe tanto semplice quanto errata. A prima vista, i pazienti trattati con antibiotici entro le prime 24 ore mostrano una mortalità superiore del 3,54% rispetto agli altri, con una significatività statistica che sembrerebbe indiscutibile.

Tuttavia, sappiamo che la realtà della terapia intensiva è più complessa. Questi pazienti non sono stati scelti a caso: sono i più critici fin dal momento del ricovero. Presentano punteggi APACHE più alti, un quadro clinico compromesso e numerose comorbidità. In breve, i medici hanno somministrato l'antibiotico proprio a chi ne aveva più bisogno; purtroppo, quegli stessi pazienti avevano già una probabilità di decesso naturalmente più alta.

Siamo di fronte a un classico caso di *confounding by indication*: trattamento e prognosi sono così intimamente legati che i soli dati grezzi non possono separarli. Per risolvere questo enigma abbiamo utilizzato metodi come IPW e AIPW, cercando di rispondere a una domanda più profonda: *cosa sarebbe successo se quegli stessi pazienti, a parità di gravità, non avessero ricevuto l'antibiotico precoce?*

8.2 Cosa cambia quando i conti tornano

Una volta bilanciati i gruppi per rendere il confronto equo, il quadro cambia radicalmente.

Utilizzando l'**IPW**, la differenza di mortalità crolla allo 0,07%. Si tratta di un valore così vicino allo zero da essere, di fatto, indistinguibile da esso. L'intervallo di confidenza ($-2,85\%$, $+4,45\%$) include lo zero: non possiamo confermare né un beneficio né un danno. Ciò che è certo, però, è che il preoccupante $+3,54\%$ iniziale era solo un miraggio statistico.

L'**AIPW**, che aggiunge un ulteriore livello di protezione (essendo "doppiamente robusto"), conferma questa lettura: $+0,14\%$ con un intervallo tra $-3,46\%$ e $+2,96\%$. Quando due approcci metodologici diversi portano alla stessa conclusione, la nostra fiducia nel risultato aumenta: non siamo di fronte a un'anomalia del modello, ma a un segnale coerente. Inoltre, l'AIPW si è dimostrato leggermente più preciso, riducendo l'ampiezza dell'intervallo di confidenza proprio come previsto dalla teoria.

8.3 Il duello tecnologico: DR Learner (XGBoost) vs DragonNet

Un aspetto particolarmente interessante emerge dal confronto tra il **DR Learner** (basato su XGBoost) e **DragonNet**. Mentre i primi metodi producono stime soli-

de, DragonNet mostra una precisione quasi nulla: il suo intervallo di confidenza oscilla tra $-59,17\%$ e $+71,60\%$. Un'ampiezza di oltre 130 punti percentuali rende, purtroppo, questa stima inutilizzabile nella pratica clinica.

Perché questa discrepanza? La chiave risiede nella **dimensione del nostro dataset**. Con 1.980 pazienti, ci troviamo in un'area grigia per il *deep learning*. Modelli come DragonNet richiedono solitamente decine di migliaia di esempi per addestrare correttamente le loro architetture profonde. Con un campione ridotto, il modello tende a inseguire il "rumore" dei dati (overfitting) anziché i pattern reali, facendo esplodere la varianza [Naser 2026; «Small data, big challenges: Machine- and deep-learning strategies for data-limited drug discovery» 2026].

Al contrario, i modelli basati su alberi come **XGBoost** sono i veri specialisti dei dati tabulari di medie dimensioni. Riescono a gestire bene le variabili senza bisogno di una preparazione eccessiva e sono naturalmente resistenti all'overfitting. Come suggerito da Kiriakidou e colleghi, la superiorità dei modelli *tree-based* in questi contesti è ormai un punto fermo nella letteratura: quando i dati non sono massivi, un buon algoritmo a gradient boosting supera spesso la complessità delle reti neurali.

8.4 Riflessioni pratiche

In termini semplici: **non abbiamo trovato prove che anticipare l'antibiotico entro le 24 ore modifichi le probabilità di sopravvivenza**.

Attenzione, però: questo non significa che l'antibiotico sia inutile. Significa che, nella media della nostra popolazione e una volta corretta la gravità dei pazienti, non emerge un beneficio netto evidente. Potrebbe esistere un effetto molto piccolo che il nostro studio non è riuscito a isolare, ma l'impatto massiccio che alcuni si aspetterebbero non è supportato dai dati.

8.5 I limiti del nostro sguardo

Ogni ricerca ha i suoi limiti, quelli che abbiamo riscontrato sono:

- **Variabili nascoste:** Abbiamo considerato 30 fattori, ma rimarranno sempre elementi non misurati (come la velocità della diagnosi o decisioni cliniche non scritte) che potrebbero influenzare i risultati.
- **Potenza statistica insufficiente:** Con $n = 1{,}980$ pazienti, 394 trattati e 160 eventi di mortalità, la potenza statistica dello studio è limitata. Gli intervalli di confidenza al 95% ottenuti con tutti gli stimatori sono compatibili sia con effetti clinicamente rilevanti di riduzione della mortalità che con effetti di aumento, rendendo impossibile escludere benefici o danni reali degli antibiotici precoci sulla base di questo solo campione.

- **Dimensionalità del dataset:** Abbiamo considerato come dataset del progetto *unicamente* la versione **demo** del dataset eICU-CRD, il motivo principale per il quale il nostro approccio Deep Learning non è risultato in qualcosa di soddisfacente. Un lavoro futuro **deve** comprendere il dataset completo se si vuole studiare il modello DragonNet. Sarebbe inoltre interessante poi confrontare modelli Deep Learning based con i Tree based.

8.6 Sintesi dei risultati

La tabella 4 riassume il viaggio statistico che abbiamo compiuto.

Tabella 4. Sintesi dell'effetto causale stimato (ATE)

Metodo	ATE	IC 95%	Interpretazione
Dato Grezzo	+3,54%	–	Risultato fuorviante
IPW	+0,07%	$[-2,85\%, +4,45\%]$	Effetto nullo
AIPW	+0,14%	$[-3,46\%, +2,96\%]$	Conferma effetto nullo
DragonNet	-1,86%	$[-59,17\%, +71,60\%]$	Troppa incertezza
DR Learner	+1,23%	$[-0,86\%, +4,47\%]$	Coerente con IPW/AIPW

8.7 Conclusione

La differenza iniziale era reale, ma non era causale: era solo lo specchio di quanto fossero gravi i pazienti. Una volta pulito il dato, l'effetto svanisce.

Anche se può sembrare deludente non trovare un beneficio eclatante, questo risultato è prezioso. Ci insegna che forse, per migliorare davvero la sopravvivenza in ICU, non basta agire solo sul tempo di somministrazione antibiotica, ma dobbiamo continuare a cercare altrove, mettendo in discussione ciò che diamo per scontato.

A Appendice: Iperparametri dell'Analisi

La presente appendice riporta in dettaglio gli iperparametri utilizzati per ciascun metodo di stima impiegato nell'analisi causale. La loro specificazione è essenziale per garantire la riproducibilità dei risultati.

A.1 Modello Logistico per il Propensity Score

Il propensity score è stato stimato mediante regressione logistica con regolarizzazione ℓ_2 (ridge). Gli iperparametri sono riportati nella Tabella 5.

Tabella 5. Iperparametri del modello logistico regolarizzato

Iperparametro	Valore / Giustificazione
Regolarizzazione C	0.1 – Previene overfitting
Massimo iterazioni	1000 – Garantisce convergenza dell'algoritmo
Tollerenza convergenza	1×10^{-4} – Criterio standard (default)

A.2 Inverse Probability Weighting (IPW)

Per il calcolo dei pesi IPTW stabilizzati è stata applicata una procedura di clipping. La Tabella 6 riassume l'unico iperparametro coinvolto.

Tabella 6. Iperparametri per IPTW

Iperparametro	Valore / Giustificazione
Clipping percentile	99° – Riduce la variabilità dovuta a pesi estremi

A.3 Bootstrap per Intervalli di Confidenza

Gli intervalli di confidenza al 95% sono stati stimati mediante bootstrap non parametrico.

Tabella 7. Iperparametri del bootstrap

Iperparametro	Valore / Giustificazione
Numero di iterazioni B	500 – Compromesso tra precisione degli IC e costo computazionale
Metodo di campionamento	Non parametrico con reimmissione – Standard per stima di IC

A.4 DR Learner con XGBoost

Il Doubly Robust Learner è stato implementato utilizzando XGBoost come modello di base sia per il propensity score che per l'outcome. La Tabella 8 elenca gli iperparametri principali.

Tabella 8. Iperparametri di XGBoost per il DR Learner

Iperparametro	Valore / Giustificazione
Numero di estimator ($n_estimators$)	100 – Numero di alberi boosting
Profondità massima (max_depth)	3 – Alberi poco profondi riducono l'overfitting
Learning rate (eta)	0.3 – Default XGBoost
Funzione obiettivo ($objective$)	$reg : squarederror$ – Appropriata per outcome continuo
Sottocampionamento ($subsample$)	1.0 – Default (nessun sottocampionamento)

A.5 Riepilogo degli Iperparametri

Per una consultazione rapida, la Tabella 9 riassume tutti gli iperparametri utilizzati nell'analisi.

Tabella 9. Riepilogo completo degli iperparametri

Metodo	Iperparametro	Valore / Giustificazione
Logistico PS	Regolarizzazione C	0.1 – Previene overfitting
Logistico PS	Massimo iterazioni	1000 – Garantisce convergenza
IPTW	Clipping percentile	99° – Riduce pesi estremi
Bootstrap	Iterazioni B	500 – Compromesso precisione/costo
Bootstrap	Metodo campionamento	Non parametrico con reimmissione
XGBoost	$n_estimators$	100 – Numero di alberi
XGBoost	max_depth	3 – Previene overfitting
XGBoost	$learning_rate$	0.3 – Default
XGBoost	$objective$	$reg : squarederror$ – Outcome continuo

A.6 Note sulla Selezione degli Iperparametri

Gli iperparametri sono stati selezionati sulla base di valori raccomandati in letteratura (per clipping e bootstrap) o mantenuti ai valori di default delle librerie software

utilizzate (scikit-learn per la regressione logistica, XGBoost per il DR Learner). Non è stata eseguita una procedura di ottimizzazione estensiva (es. grid search o validazione incrociata) poiché l'obiettivo primario dell'analisi era la stima dell'effetto causale (ATE) piuttosto che la massimizzazione della predittività dei modelli. Questa scelta è coerente con la pratica comune nella letteratura di *target trial emulation*, dove l'attenzione è focalizzata sul bilanciamento delle covariate e sulla riduzione del bias piuttosto che sull'accuratezza predittiva Hernán et al. 2022.

Riferimenti bibliografici

Austin, Peter C. e Elizabeth A. Stuart (2015). «Moving towards best practice when using inverse probability of treatment weighting (IPTW) using the propensity score to estimate causal treatment effects in observational studies». In: *Statistics in Medicine* 34.28, pp. 3661–3679. DOI: 10.1002/sim.6607.

Fu, Edouard L. (2023). «Target Trial Emulation to Improve Causal Inference from Observational Data: What, Why, and How?» In: *Journal of the American Society of Nephrology* 34.8, pp. 1305–1314. DOI: 10.1681/ASN.0000000000000152.

Hernán, Miguel A., Wei Wang e David E. Leaf (2022). «Target Trial Emulation: A Framework for Causal Inference From Observational Data». In: *JAMA* 328.24, pp. 2446–2447. DOI: 10.1001/jama.2022.21383.

Naser, M. Z. (gen. 2026). «A review of machine learning with small and limited data». In: *Journal of Big Data*. ISSN: 21961115. DOI: 10.1186/s40537-025-01346-9.

Pollard, Tom J. et al. (set. 2018). «The eICU collaborative research database, a freely available multi-center database for critical care research». In: *Scientific Data* 5. ISSN: 20524463. DOI: 10.1038/sdata.2018.178.

Shi, Claudia, David M. Blei e Victor Veitch (ott. 2019). «Adapting Neural Networks for the Estimation of Treatment Effects». In: URL: http://arxiv.org/abs/1906.02120.

«Small data, big challenges: Machine- and deep-learning strategies for data-limited drug discovery» (feb. 2026). In: *Advanced Drug Delivery Reviews* 229. ISSN: 18728294.

Yao, Liuyi et al. (giu. 2021). *A Survey on Causal Inference*. DOI: 10.1145/3444944.